

Software Project Specification Document

Project Title: *You Only Localize Once : Lightweight Vision-Language Embedding Retrieval for Zero-Shot Product Recognition on Edge Devices*

Author(s): 孫加恩、李承育、杜宇烽

Date: 4/22/2026

Version: 1.0

1. Introduction

1.1 Purpose

在零售與餐飲場域中，結帳流程長期依賴人工操作，不僅增加人力成本，也容易在高峰時段造成排隊壅塞與效率瓶頸。因此，自助結帳 (Self-checkout) 與輔助結帳系統逐漸成為提升營運效率的重要解決方案，透過人機協作的方式，加速交易流程並降低人為錯誤率。

儘管近年來市面上已存在成熟的自助結帳設備，例如大型連鎖超市所採用的整合式影像辨識與感測系統，其在準確率與穩定性上已達商業可用水準，但此類系統普遍存在高建置成本、硬體依賴性強與部署複雜等問題。對於中小型商家 (如麵包店、自助餐店、雜貨店) 而言，這些解決方案在經濟與技術門檻上皆難以落地，導致自動化結帳技術的普及性仍然受限。另一方面，基於傳統電腦視覺方法的商品辨識系統 (例如使用 YOLO 系列模型 ([6], [7]) 進行物件偵測與分類) 已被廣泛研究與應用，包含過去實作之自助餐結帳系統。然而，此類方法通常依賴監督式學習 (Supervised Learning)，需要大量標註資料進行模型訓練，並且在商品新增或變動時，需重新蒐集資料與訓練模型。對於缺乏工程資源與資料蒐集能力的商家而言，這種高維護成本與低擴展性的特性，使其難以成為實際可持續運作的解決方案。

隨著深度學習技術的發展，特別是 2021 年提出的 CLIP (Contrastive Language-Image Pretraining) [1]，開啟了 Vision-Language 模型在跨模態理解上的新方向。此類模型透過將影像與語意映射至共同的嵌入空間，使系統具備 Zero-shot 或 One-shot 的辨識能力，無需針對每一類別進行重新訓練。近年來相關技術 (如 SigLIP [2]、MobileCLIP [3]) 進一步朝向輕量化與實用化發展，使其具備在實際應用場景中解決問題的潛力。

基於上述背景，本專題旨在設計並實作一套輕量化的 Vision-Language 商品辨識系統，採用 embedding retrieval 的方式，實現 Zero-shot Product Recognition。系統允許使用者僅透過上傳少量商品資訊 (如單張圖片、名稱與價格)，即可建立可用的商品辨識資料庫，無需進行模型訓練或複雜設定。本系統將以低成本與高可用性為核心設計目標，支援部署於 Edge Device (如 Raspberry Pi)，並提供簡潔直觀的操作介面，使非工程背景使用者亦能輕易建立與維護商品辨識系統。透過此設計，我們期望降低智慧結帳系統的導入門檻，促進自助結帳技術在中小型商業場域中的實際應用，並實現具擴展性與實用性的智慧零售解決方案。

1.2 Scope

In Scope

- **Zero-shot 商品辨識機制**：本系統採用 Vision-Language 模型之 embedding 表示，實現 Zero-shot 商品辨識能力。系統在推論階段不需針對新商品進行模型訓練，而是透過將輸入影像轉換為語意向量，並與既有商品資料庫中的向量進行相似度比對（如 cosine similarity），以取得最相似的商品類別。此機制可大幅降低系統在商品新增或變動時的維護成本，並提升系統的擴展性與部署彈性，使其適用於商品種類頻繁變動的零售場域。
- **商品資料註冊與管理**：系統提供商家端商品註冊介面，允許使用者上傳商品圖片、輸入商品名稱與價格等基本資訊。於註冊流程中，系統會自動使用 Vision-Language 模型將商品圖片轉換為 embedding，並與商品資訊一併儲存於資料庫中。此設計避免傳統監督式學習所需的大量標註與訓練流程，使非工程背景使用者亦可快速建立商品辨識系統。此外，系統支援基本的商品資料更新與刪除功能，以維持資料庫一致性。
- **Embedding Retrieval 與相似度搜尋**：本系統核心採用向量檢索 (Embedding Retrieval) 機制進行商品辨識。所有商品 embedding 將儲存於向量資料庫中 (如 FAISS)，並於推論時透過高效率的近似最近鄰搜尋 (Approximate Nearest Neighbor, ANN) 取得相似度最高的候選商品。系統支援 Top-k 檢索結果輸出，以利後續進行準確率評估或 re-ranking 處理。此架構可在維持辨識效能的同時，確保在 Edge Device 上具備可接受的推論延遲。
- **商品區域擷取 (Region Proposal)**：為提升商品辨識準確率，本系統於影像輸入後，先透過輕量化物件偵測模型進行商品區域擷取 (Region Proposal)。系統僅需取得商品之 bounding box，並將該區域裁切後輸入至 Vision-Language 模型進行 embedding 計算，而不進行分類任務。此設計可降低模型複雜度並提升推論效率，同時減少背景雜訊對辨識結果的影響，使系統更適合部署於資源受限之 Edge Device。
- **自助結帳流程整合**：本系統提供簡化之自助結帳流程，整合商品辨識結果以輔助結帳操作。當系統完成商品辨識後，將顯示對應之商品名稱與價格，供使用者確認並進行後續結帳步驟。此流程著重於人機協作，提升結帳效率並降低人工輸入錯誤之可能性。系統不包含金流處理功能，而是專注於辨識與資訊呈現層之實作。

Out of Scope

本系統之設計重點在於驗證輕量化 Vision-Language embedding retrieval 應用於 Zero-shot 商品辨識之可行性，因此在功能與應用範圍上進行適當界定，以聚焦研究目標與系統實作。本專題不涵蓋完整商業級 POS 系統功能，例如發票開立、庫存管理、會員管理與營運報表分析等後台機制，亦不包含任何金流與支付整合（如信用卡、電子支付或第三方支付服務串接）。在電腦視覺能力方面，本系統不處理高精度多物件追蹤 (multi-object tracking) 或複雜行為分析，亦不針對高度複雜場景（如嚴重遮擋、多商品重疊或動態交互）進行最佳化設計，而是聚焦於單商品或簡單多商品情境之辨識任務。此外，本專題不涉及大型 Vision-Language 模型之從頭訓練或大規模雲端訓練流程，而是以既有 pre-trained 模型為基礎，搭配輕量化與推論優化技術，以符合 Edge Device 部署需求。最後，本系統亦不考慮跨店共享資料庫或大規模商業部署架構，而是以單一店面 (single-store) 為主要應用情境，強調系統之低成本導入與實務可行性。

1.3 Definitions, Acronyms, and Abbreviations

Term	Definition
API	Application Programming Interface
bbox	Bounding Box.
CLIP	Contrastive Language-Image Pretraining.
Edge Device	A computing device with limited resources.
Embedding	A dense vector representation of an image or text that captures semantic meaning in a high-dimensional space.
FAISS	Facebook AI Similarity Search - An open-source library for efficient similarity search and clustering of dense vectors.
Few-shot Learning	A machine learning paradigm where the model can generalize from only a small number of training examples per class.
Inference	The process of using a trained model to make predictions on new, unseen data.
Lightweight Model	A neural network model optimized for low computational cost, memory usage, and latency, suitable for deployment on resource-constrained edge devices.
Product Registration	The process in which a store owner uploads product images, names, and prices to build the product database.
Re-ranking Model	A custom-trained lightweight model used to refine the initial ranking results from vision-language embeddings.
Region Proposal	The process of generating candidate bounding boxes that may contain products in a captured image.
UI	User Interface
Vector Database	A database specialized in storing and querying high-

	dimensional vector embeddings efficiently.
Vision-Language Model (VLM)	A multimodal model that jointly understands images and natural language, enabling zero-shot recognition.
Zero-shot Learning	The ability of a model to recognize or classify objects it has never seen during training, using only semantic information.

1.4 References

- [1] Radford, Alec, et al. "Learning Transferable Visual Models from Natural Language Supervision." *ArXiv:2103.00020 [Cs]*, 26 Feb. 2021, arxiv.org/abs/2103.00020.
 - [2] Zhai, Xiaohua, et al. "Sigmoid Loss for Language Image Pre-Training." *ArXiv.org*, 2023, arxiv.org/abs/2303.15343.
 - [3] Vasu, et al. "MobileCLIP: Fast Image-Text Models through Multi-Modal Reinforced Training." *ArXiv.org*, 2023, arxiv.org/abs/2311.17049.
 - [4] Hugging Face (CLIP) : https://huggingface.co/docs/transformers/model_doc/clip
 - [5] YOLO-Based Self-Checkout : <https://arxiv.org/html/2407.21308v2>
 - [6] Tian, Yunjie, et al. "YOLOv12: Attention-Centric Real-Time Object Detectors." *ArXiv.org*, 2025, arxiv.org/abs/2502.12524.
 - [7] "YOLO26: An Analysis of NMS-Free End to End Framework for Real-Time Object Detection." *Arxiv.org*, 2018, arxiv.org/html/2601.12882v2. Accessed 15 Apr. 2026.
 - [8] Hugging Face : <https://huggingface.co/>
 - [9] Ultralytics : <https://www.ultralytics.com/>
 - [10] PyTorch : <https://pytorch.org/>
 - [11] NanoDet-Plus : <https://github.com/RangiLyu/nanodet>
 - [12] Douze, Matthijs, et al. "The Faiss Library." *ArXiv.org*, 16 Jan. 2024, arxiv.org/abs/2401.08281.
-

2. Overall Description

2.1 Product Perspective

該系統被設計成一個模組化、可邊緣部署的產品識別和結帳解決方案，可在現有的零售環境中以兩種主要配置運作。



Fig.1. 左圖展示獨立式邊緣支付系統，右圖展示適用於現有 POS 系統的嵌入式軟體模組

(1) 獨立式邊緣支付系統

在獨立配置中，該系統作為獨立的結帳單元運行，部署在邊緣設備（例如 Raspberry Pi）上，整合了攝影機和緊湊型顯示器。

- 該設備使用輕量級視覺語言嵌入模型進行設備端推理
- 產品識別是透過向量相似性搜尋實現的
- 本系統直接處理：
 - I. 產品檢測
 - II. 價格檢索
 - III. 結帳介面

這種設置適用於缺乏現有 POS 基礎設施的小型企業（例如麵包店、文具店）。

(2) 適用於現有 POS 系統的嵌入式軟體模組

在第二種配置中，該系統被設計為一個軟體模組，可以整合到現有的銷售點 (POS) 系統中。

- 識別管道充當後端人工智慧服務

- 提供以下 API：
 - I. 產品識別
 - II. 嵌入檢索
 - III. 相似性匹配
- 可整合到：
 - I. 收銀系統
 - II. 自助結帳亭
 - III. 庫存系統

這使得該系統能夠在不取代整個 POS 系統的情況下增強現有的零售工作流程。

2.2 Product Functions

- Allow users to register new products by uploading product images, names, and prices.
- Allow the system to capture product images using a camera device.
- Allow the system to display the recognized product name and price to the user.
- Allow users to add recognized products to a checkout list.
- Allow the system to calculate the total price of selected products.
- Allow the system to operate on edge devices with limited computational resources.
- Allows for the correction of identification errors or modification of checkout lists during checkout system runtime.

2.3 User Characteristics

該系統的目標使用者是小型企業主，例如麵包店老闆、文具店經營者以及其他需要簡單且有效率的產品識別和結帳解決方案的零售商。大多數使用者預計不具備技術背景，且在機器學習或軟體開發方面經驗有限。他們通常熟悉基本的電腦操作，例如使用網頁瀏覽器、上傳文件以及與圖形使用者介面互動。

該系統以降低學習曲線為主要設計目標。使用者只需上傳產品圖片以及基本元資料 (例如產品名稱和價格) 即可在系統中註冊商品。使用者無需進行任何模型訓練、參數調優或技術配置。在原型階段，該系統可透過 GitHub 等平台分發，只需進行少量設定 (例如執行腳本或安裝依賴項)。然而，該系統在設計時已考慮到未來的可擴展性，因此可以將其打包成一個獨立的應用程序，用戶可以輕鬆下載並運行，只需極少的安裝工作。

總而言之，該系統旨在最大限度地減少用戶操作難度和技術門檻，使用戶無需具備人工智慧或程式設計方面的專業知識即可快速上手並運行該系統。

2.4 Constraints

Technical Constraints

- 該系統必須能夠在資源受限的邊緣設備上運行，這些設備 CPU、記憶體有限，且沒有專用 GPU。
- 該系統必須支援即時或近實時推理，以確保結帳場景的延遲在可接受範圍內。
- 該系統必須在輕量級模型限制下運行，需要高效的模型架構和最佳化的推理（例如 ONNX 或類似格式）。
- 該系統必須支援離線或低連接環境，所有核心功能都可以在沒有持續網路連線的情況下運作。
- 該系統必須能夠處理有限的訓練數據，因為每個產品可能只有一張或幾張參考圖像。
- 即使註冊產品數量增加，系統也必須確保可擴展的向量檢索效能。
- 原型實作可能依賴特定的框架和函式庫（例如 FastAPI、FAISS），這可能會引入不同平台之間的相容性限制。

Legal and Regulatory Constraints

- 收集的任何圖像資料都必須遵守資料隱私法規，確保使用者上傳的內容僅用於產品識別目的。
- 該系統必須尊重智慧財產權，確保上傳的產品圖片不違反版權或授權限制。

Deployment Constraints

- 該系統必須能夠在對基礎設施要求極低的小型零售環境中部署。
- 該系統應盡可能減少安裝和配置工作量，尤其對於非技術用戶而言。
- 該系統的未來版本應支援打包分發，以減少對 GitHub 設定等開發環境的依賴。

2.5 Assumptions and Dependencies

Assumptions

- 假設使用者擁有能夠拍攝出品質足以進行辨識的產品影像的相機設備。
- 假設使用者可以為每個產品提供至少一張參考圖片，以及產品名稱和價格等基本元資料。
- 假設所拍攝的產品影像相當清晰，沒有嚴重遮擋，從而使系統能夠提取有意義的視覺特徵。
- 假設系統中的產品數量保持在可管理的範圍內，從而確保高效的檢索效能。
- 假設使用者具備基本的電腦操作能力，例如操作網頁介面和上傳文件。
- 對於原型使用，假設使用者可以執行基本的設定步驟（例如，運行程式或安裝所需的軟體包）。

Dependencies

- 該系統依賴預先訓練的視覺語言模型 (例如 CLIP、MobileCLIP、SigLIP) 來產生影像嵌入。
- 該系統依賴向量相似性搜尋庫進行高效的最近鄰檢索。
- 該系統依賴資料庫系統來儲存產品元資料。
- 該系統依賴後端框架來處理 API 請求和系統邏輯。
- 該系統依賴邊緣設備的硬體能力 (例如 CPU / GPU 效能、記憶體容量)，這直接影響系統的延遲和效能。
- 該系統可能依賴模型轉換和推理框架以在邊緣設備上進行最佳化部署。

3. Specific Requirements

3.1 Functional Requirements

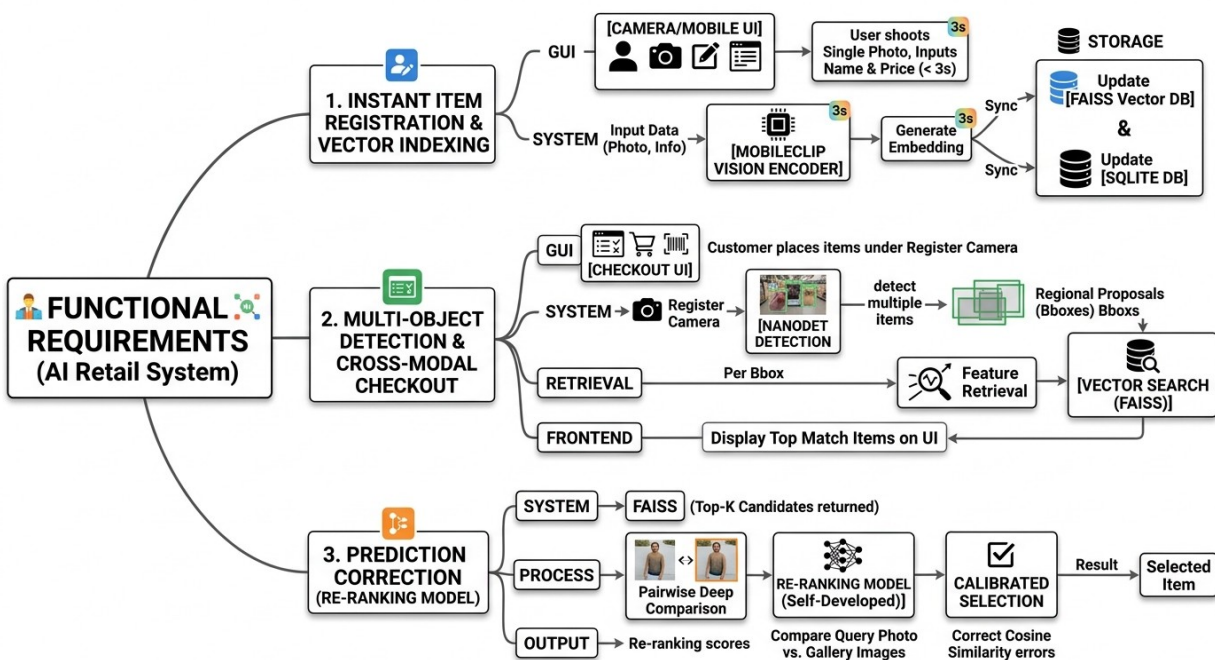


Fig. 2. Functional Requirements Diagram

- **FR1: 即時商品註冊與向量索引建檔**

使用者僅需透過行動裝置拍攝單張商品照片並輸入名稱與價格，系統需在 3 秒內透過 Encoder 生成 Embedding，並同步更新至向量資料庫與 SQLite 關聯式資料庫。

- **FR2: 多目標偵測與跨模態檢索結帳**

當顧客將商品放置於收銀台相機下，系統需自動執行進行物件偵測，並對每個 Bbox 進行特徵檢索，最後顯示匹配度最高的商品資訊於前端 UI。

- **FR3: 基於 Re-ranking 模型之預測校正**

當檢索回傳 Top-K (, where $k = 5$) 個候選商品後，系統必須呼叫開發者自研的 Re-ranking (Matching) Model，對 Query 圖片與 Gallery 圖片進行 Pairwise 深度比對，以校正單純 Cosine Similarity 可能產生的誤判。

3.2 Non-Functional Requirements




Fig. 3. Non-Functional Requirements Diagram

- **即時商品註冊與向量索引建檔：**

系統必須保證在加入「從未見過」的新品項時，其辨識準確率 (Zero-shot Accuracy) 與既有商品無顯著差異，且店家端完全不需要具備任何標記數據或深度學習訓練知識。

Top 1 Accuracy $\geq 85\%$ • Top 5 Accuracy = 100%

- **邊緣端低延遲交互體驗：**

系統在 Raspberry Pi 等邊緣設備上運行時，從相機擷取影像到顯示結帳結果的端到端 (End-to-End) 延遲必須小於 1000ms，以避免顧客在結帳時感到明顯卡頓。

Inference Latency on Raspberry Pi (using ONNX Runtime) $\leq 1.0s$

- **輕量化與資源受限環境之部署彈性：**

全系統 (含偵測、編碼、重排序模型) 的記憶體佔用 (RAMUsage) 需控制在 Raspberry Pi 的硬體限制內 (如 4GB/8GB RAM)，且模型必須轉換為 ONNX 格式以最大化邊緣端

硬體加速器的利用率。

Model Size <= 500MB ; RAM Usage <= 2GB

3.3 External Interfaces

- **Website API Interfaces** : The system provides RESTful APIs implemented using FastAPI or Flask for product registration, retrieval, and recognition services.
- **MLOPS Interfaces** : The system integrates with machine learning frameworks such as PyTorch, Hugging Face Transformers, and Ultralytics for model inference and management.
- **Database** : The system uses SQLite for structured data storage and FAISS or Chroma for vector embedding retrieval.
- **Edge Computing Systems** : The system supports deployment on edge computing devices such as Raspberry Pi and Jetson Orin Nano, enabling on-device inference.

3.4 User Story & Inspiration

在本系統設計中，我們透過一個具體的使用者故事來萃取需求。假設一位小型麵包店店主，在人力成本高昂且預算有限的情況下，無法導入傳統自助結帳機或雇用額外員工。該使用者期望能以低成本方式提升結帳效率，同時不需具備機器學習或系統操作的專業背景。


從此情境出發，可以歸納出幾項關鍵需求。首先，系統必須具備「低學習門檻」，使用者應能透過簡單操作完成商品註冊。其次，「無需重新訓練模型」成為核心需求，避免傳統模型在新增商品時帶來的時間與技術成本。此外，「輕量化部署」亦為重要條件，使系統可運行於如 Raspberry Pi 等邊緣設備，降低硬體支出。

在結帳流程中，使用者期望系統能即時辨識商品並顯示價格，因此需具備快速且準確的影像辨識能力。同時，考量實際商業環境中商品多樣且可能頻繁變動，系統需支援 Zero-shot 辨識機制，以提升彈性與可擴展性。


綜合上述使用者故事所帶來的洞察，本系統應設計以下功能：商品快速註冊介面、基於 Vision-Language 的 embedding 建立機制、向量資料庫檢索、即時影像辨識與結帳顯示模組，以及可部署於邊緣裝置的輕量化模型。此設計能有效回應使用者在成本、易用性與效率上的需求，並提供一個實際可行的自助結帳解決方案。

透過 User Story 啟發可以幫助使用者解決的問題：

1. 高昂的人力與傳統自助結帳機成本，讓小型麵包店無法負擔額外員工或昂貴設備。
2. 新增商品時需重新訓練模型與大量標註資料，導致小型店家難以維護系統。
3. 電腦視覺模型在真實商店場景中缺乏足夠的訓練資料，造成辨識準確率低且難以擴展。
4. 傳統結帳系統部署門檻高，無法在 Raspberry Pi 等低成本邊緣設備上高效運行。
5. 非技術背景店家缺乏專業知識，無法自行調整或擴充商品辨識系統。



Jensen Huang owns a bakery and needs other employees to help him with checkout, but human resources are too expensive, but he doesn't have the budget to buy self-checkout machines. Jensen Huang told Andrej Karpathy that he wanted him to help him build a cheap, lightweight, small scale automated checkout system.




Andrej Karpathy is thinking about how to make the model faster and lighter for use in Jetson Nano or RaspberryPi. Furthermore, the entire system needs to be compatible with the domain application and achieve high accuracy

Zero-Shot Insight



Andrej Karpathy realized that if the model needed to be tailored to each user's context, it would need to be fine-tuned. However, fine tuning is time-consuming, requires data, and is difficult to implement outside of engineering fields. Therefore, he decided to create a zero-shot solution to change the entire field.

Delivery and Success



Andrej Karpathy delivered a complete zero-shot system that was lightweight, perfect, and inexpensive for Jensen Huang's bakery. Jensen Huang's bakery is now operating much better thanks to this small self checkout machine

BAKERY: SUCCESS

4. System Design Overview

4.1 High-Level Architecture (UMLs)

USE CASE UML DIAGRAM




Fig. 4. Use Case Diagram of the Lightweight Vision-Language Zero-Shot Product Recognition System

此用例圖展示了所提出系統的功能需求，該系統旨在幫助非技術型店主快速建立用於邊緣設備自助結帳的零樣本產品識別系統。此圖分為兩個主要子系統：產品註冊（上部，綠色）和邊緣結帳（下部，藍色）。在產品註冊子系統中，店主（非技術型商家）可以透過上傳單一產品圖片及其名稱和價格，以零樣本的方式註冊新產品。此過程包括使用輕量級模型（例如 MobileCLIP 或

SigLIP) 產生視覺語言嵌入，並將嵌入及其元資料儲存在基於 SQLite 的向量資料庫中。其他用例，例如管理產品目錄和更新產品信息，支援持續的產品目錄維護。

在邊緣結帳子系統中，收銀員與部署在 Raspberry Pi 上的系統交互，以執行即時產品識別。該流程包括從攝影機捕獲影像、執行區域提議和裁剪、生成嵌入以及透過餘弦相似度檢索最相似的產品。該系統整合了一個由作者訓練的重新排序模型作為擴展，以在置信度不足的情況下提高零樣本和少樣本的準確率。如果置信度得分低於預先定義的閾值，則「處理低置信度/錯誤」用例允許手動幹預。然後顯示識別出的產品資訊以完成結帳流程。

該設計強調零樣本學習，無需為新產品重新訓練，並且輕量級部署，適用於資源受限的邊緣設備。註冊和推理階段的分離確保了非工程師也能輕鬆使用，同時在邊緣硬體上保持即時效能。所提出的重排序模型是主要研究貢獻，旨在提高檢索準確率而不增加延遲。

SYSTEM ARCHITECTURE DESIGN




Fig. 5. System Architecture Design Diagram for “You Only Localize Once : Lightweight Vision-Language Embedding Retrieval for Zero-Shot Product Recognition on Edge Devices”

本系統採用模組化、輕量化的 Vision-Language Retrieval 架構，專為 Edge Device 上的零樣本商品辨識而設計，分為兩個主要階段：Product Registration (商品註冊/圖庫建置) 與 Real-time Inference (即時推論/結帳)。

在商品註冊階段，店家僅需上傳單張商品圖片與文字標籤 (商品名稱、價格)。系統透過 MobileCLIP-ViT 視覺編碼器提取高維視覺嵌入向量，結合文字標籤後一同存入混合資料庫：視覺嵌入儲存於 FAISS Vector Database，文字與價格則儲存於 SQLite。整個註冊流程無需任何模型微調，實現真正的 Zero-shot 設定。

在即時推論階段，Edge Device 上的相機擷取即時影像，先由輕量物件偵測模型 NanoDet 進行 Region Proposal，產生商品邊界框 (bbox) 後進行裁切與調整大小。裁切後的商品影像同樣經 MobileCLIP-ViT 提取嵌入向量，與 FAISS 中儲存的商品嵌入進行余弦相似度檢索 (Zero-Shot

Retrieval)。為進一步提升準確率，本研究額外設計並自行訓練一個 Re-ranking / Matching Model (由特徵融合層與密集層組成)，將 Top-k 檢索結果與視覺特徵進行再排序，輸出最終商品識別結果，並結合 SQLite 中的價格資訊完成自助結帳。本架構全部模型均轉換為 ONNX 格式部署於 Raspberry Pi 4，確保低延遲與輕量特性。

ACTIVITY UML DIAGRAM

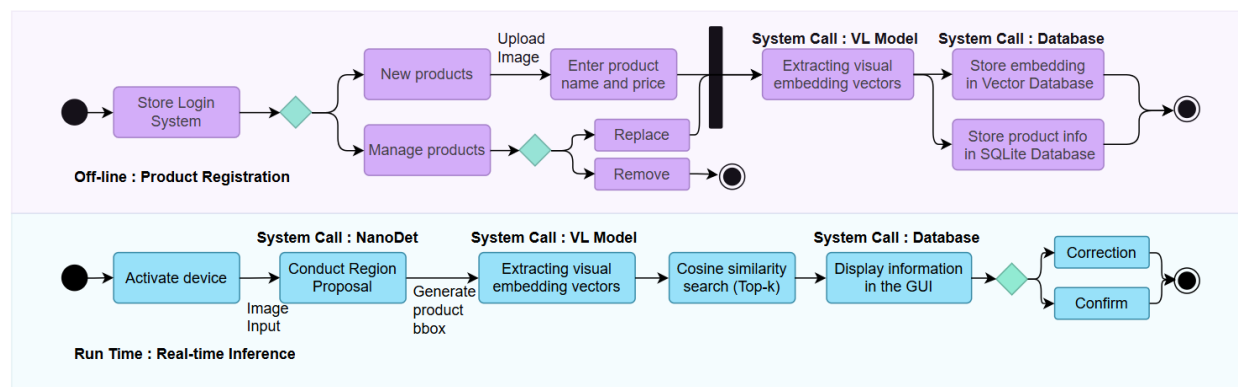


Fig. 6. User Activity Diagram

本圖呈現系統兩大核心使用者活動流程。上半部為離線商品註冊流程 (Offline: Product Registration)，店家登入後可新增、替換或移除商品，僅需上傳單張圖片與輸入名稱、價格，系統即自動透過 MobileCLIP 提取視覺嵌入並存入 FAISS 與 SQLite，實現 Zero-shot 圖庫建置。

下半部為即時推論流程 (Run Time: Real-time Inference)，於 Raspberry Pi 4 上執行。系統透過 NanoDet 產生商品邊界框後，提取嵌入向量進行 cosine similarity 檢索，再由自行訓練的 Re-ranking Model 提升準確率，最終完成自助結帳。該活動圖清楚展示系統操作簡易性與 Edge AI 即時特性。

4.2 ML System Design & MLOps

Object Detection Model

現有物件偵測模型，NanoDet、MobileNet-SSD、YOLOv12n / YOLOv26n 等已經在 Raspberry Pi、RK3568 等 Edge 裝置上驗證過 real-time 效能，例如 NanoDet-m 在 ARM CPU 上可達 97 FPS，模型僅 980KB INT8。而這項 Region Proposal 雛形機的任務僅專注於回應一個關鍵任務- "什麼是商品物件"，以及在圖像中辨識並抓出位置與大小。移除 classification head，只保留 objectness score + bbox regression (類似 Faster R-CNN 的 RPN，但做成 one-stage lightweight)。這能讓模型參數再減 30–50%，更適合 Pi。旨在收集 500~2000 張商品圖，各種常見商品物件，作為單一物件分類任務的資料集，並使用基於預訓練模型微調物件偵測模型達到通用商品物件偵測的效果，並配合隨機背景、亮度、旋轉、合成多物件場景增廣資料與加強訓練，期望初步訓練準確率 bbox IoU > 0.7。訓練 NanoDet-based objectness-only detector，模型以 ONNX 格式匯出。透過 Git + DVC 管理程式碼與資料版本；GitHub Actions 自動執行訓練、量化、ONNX 轉換與單元測試；實驗結果與指標存入 MLflow 追蹤。Edge 部署時以 Docker + FastAPI 打包，確保 Raspberry Pi 可重現部署，整個流程強調可重現性、版本控制與自動化。

Vision-Language Embedding Model

OpenAI 於 2021 年提出 CLIP (Contrastive Language-Image Pre-training)，利用 4 億圖文對以對比學習 (contrastive loss) 將影像與文字對齊至共享 embedding 空間，實現強大 zero-shot 能力，奠定 VLM 基礎。2021 ~ 2022 年，ALIGN、Florence 等模型擴大資料規模並優化架構；2023 年 Google SigLIP 以 sigmoid loss 取代 softmax，解決批次記憶體瓶頸，提升訓練效率與效能。2024–2025 年，MobileCLIP (Apple) 針對 edge 優化，結合輕量 backbone 與 multi-modal reinforced training，達成 3–15ms 延遲與高 zero-shot 準確率；SigLIP 2 進一步強化多語言與密集特徵。2026 年至今，輕量 VLM 持續朝低參數、高效率演進。

本項目採用 MobileCLIP / SigLIP 作為核心 embedding 模型，實現支援 zero-shot product recognition，無需重新訓練。CLIP 系列的 zero-shot 與 cosine similarity 特性完美匹配店家自助註冊與 Raspberry Pi 邊緣推論需求。我們將比較不同模型 (CLIP vs. SigLIP vs. MobileCLIP) 在 accuracy、latency 與 few-shot 表現，並自行訓練 re-ranking model 作為研究貢獻，提升商品辨識精準度。此設計兼顧 lightweight 與 VL 新技術整合，提供 edge AI 與小型商店實際部署需求。




Fig. 7. 標準圖像模型聯合訓練圖像特徵提取器和線性分類器來預測標籤，而 CLIP 則聯合訓練圖像編碼器和文字編碼器來預測一批 (圖像，文字) 訓練樣本的正確配對。取自 "Learning Transferable Visual Models From Natural Language Supervision"。

Feasibility Testing

Table. 1. Sushi Dataset Comparison (4 Classes , 78 test images)

Embedding Model	Top-1 Accuracy	Top-5 Accuracy	Avg. Similarity
CLIP	94.87%	100.00%	85.71%
ResNet	83.33%	100.00%	76.40%

Table. 2. Grocery Store Packages Dataset Comparison (31 Classes , 833 test images)

Embedding Model	Top-1 Accuracy	Top-5 Accuracy	Avg. Similarity
CLIP	51.86%	81.63%	81.94%
ResNet	39.74%	67.95%	81.52%

4.3 Technology Stack

Layer	Technology	Illustrate
Frontend	HTML/CSS/JS	Simple and intuitive Web UI
Backend	Flask or Fast API	High-performance asynchronous framework
Embedding Model	MobileCLIP-ViT (ONNX)	Lightweight Vision-Language Model
Region Proposal	NanoDet (ONNX)	Ultra-lightweight object detection model
Database	SQLite	Lightweight, zero settings
Vector Database	FAISS	High-performance vector search library
Development & Deployment Tools	Git, Docker, Docker Compose, PyTorch, ONNX Converter	Version control, containerized deployment, model conversion, and experiment reproducibility.

4.4 GUI Design




Fig. 8. 店商端 GUI 概念設計圖展示




Fig. 9. 結帳端 GUI 概念設計圖展示

5. Testing Plan

● Tools and Coverage Goal

使用工具：

- pytest (後端邏輯測試)
- unittest (模型與工具函式測試)

測試範圍 (coverage target $\geq 80\%$)：

- Embedding 產生模組 (Vision-Language Model wrapper)
- 相似度計算 (cosine similarity)
- FAISS 查詢模組
- 商品資料 CRUD (SQLite)
- API endpoints (FastAPI)

測試內容：

- 輸入圖片 $\rightarrow$ embedding 維度正確性
- Top-k retrieval 結果格式與排序正確性
- 邊界條件 (空資料庫 / 單一商品 / 重複商品)

● Integration Testing:

- 上傳商品 (圖片 + 名稱 + 價格) 與資料庫連結測試
- 系統產生 embedding 並寫入 FAISS + SQLite
- Region Proposal & Object Detection Crop
- Embedding Vector DB 查詢 & 回傳 Top-1 / Top-5 商品

- 各模組之間資料格式一致、是否符合 edge device 需求、多商品情境下的穩定性

- **User Testing:**

Scenario 1：商品建立

使用者需透過介面上傳 1 至 3 張商品圖片，並輸入商品名稱與價格資訊，完成商品資料建立流程。系統將即時產生對應 embedding 並寫入資料庫。此情境主要評估系統操作流程是否直覺，以及非技術使用者是否能在無指導情況下完成設定，並確保商品能正確被系統註冊與儲存。

Scenario 2：單商品辨識

使用者透過攝影機拍攝單一商品，系統接收影像後進行區域擷取與 embedding 計算，並從向量資料庫中檢索最相似商品，最後顯示辨識結果與價格。此情境用於驗證系統在理想單物體條件下的辨識能力與回應速度。

Scenario 3：多商品辨識

模擬實際結帳場景，畫面中同時出現多個商品，系統需透過物件偵測取得各商品區域，逐一進行 embedding 與比對，並輸出完整商品清單。此情境主要評估系統在複雜環境中的穩定性與辨識完整度。

Scenario 4：新商品 Zero-shot

使用者新增未曾出現在訓練資料中的新商品，系統不進行任何模型再訓練，直接透過 embedding 建立資料並進行辨識測試。此情境用於驗證系統 Zero-shot 能力及對新商品的泛化表現。

- **Success Criteria:**

Accuracy

1. Top-1 accuracy $\geq 70\%$ (Zero-shot)
2. Top-5 accuracy $\geq 90\%$

Performance (Edge Device)

1. 單次推論 latency ≤ 1 秒
2. 模型大小 $\leq 200\text{MB}$

System Usability

1. 新增商品流程 ≤ 1 分鐘
2. 無需技術背景即可操作

System Robustness

1. 支援至少 50–100 個商品資料庫
2. 多商品場景仍可穩定運作

6. Timeline / Milestones

Phase	Timeline	Description
Development	Week 1~3	各項模組最小可運行

Integration	Week 4~5	最小可運作系統
Model Improvement	Week 6	提升準確度、消融實驗
Testing & Evaluation	Week 7	完整實驗矩陣、成品展示
Deployment	Week 8	部屬&上線、寫報告

7. Team Member Contributions

Team Member	Responsibilities
孫加恩	System Design & AI Research
李承育	Backend Engineering & Testing Engineering
杜宇烽	UI & UX

8. Appendices

● Screenshots, Wireframes, and Mockups

商家端產品註冊系統和邊緣設備上的結帳介面的系統介面的可視化表示。

1. 商家網站使用者介面線框圖 (產品上傳、產品清單、嵌入狀態)
2. 介面模型 (相機預覽、偵測到的產品顯示、價格確認)
3. 系統互動流程圖

● Glossary

- **Zero-shot Learning:** A learning paradigm where the model can recognize unseen classes without additional training.
- **Vision-Language Model (VLM):** A model that jointly encodes images and text into a shared embedding space.
- **Embedding:** A vector representation of data used for similarity comparison.
- **Vector Database:** A database optimized for storing and retrieving high-dimensional vectors.
- **Edge Device:** A resource-constrained device where inference is performed locally.

● Supporting Data and Resources

Test Dataset : <https://github.com/marcusklason/GroceryStoreDataset>

Version History

Version	Date	Description	Dev. Log
1.0	4/22	Initial draft	完成 VLM 可行性測試、基礎前後端架構設計與內部協調，順便去已知宇宙的邊界逛了一圈，過程中不小心喝太多咖啡。

補充：錯誤處理和極端情況

為確保系統在實際部署中的穩健性，系統必須妥善處理產品識別和結帳過程中的各種極端情況。當識別置信度低於預設閾值時，系統不應直接傳回最終預測結果。而應顯示前 K 個候選產品，並允許使用者手動選擇或確認正確的商品。這可以降低因預測不確定性而導致的錯誤結帳風險。

如果在向量資料庫中未找到相似產品（即相似度得分低於最低閾值），系統應傳回「未找到產品」訊息，並可選擇性地提示使用者註冊新產品。對於資料庫中重複或高度相似的產品，系統應傳回多個按相似度排序的候選產品，並依靠重新排序模型或使用者確認來解決歧義。

對於低品質的輸入影像（例如，模糊、遮蔽或光線不足），系統應拒絕輸入並顯示警告訊息，或要求使用者重新拍攝影像。在推理之前，可以進行基本的影像品質檢查。此外，系統必須能夠妥善處理空資料庫狀態、單一產品場景以及無效的輸入格式（例如，不支援的影像類型），從而確保系統在任何情況下都能保持穩定且易於使用。

補充：資料模型

該系統維護一種混合資料結構，結合了結構化元資料和向量嵌入。每個產品條目包含以下欄位：

- product_id：唯一識別符
- name：產品名稱
- price：產品價格
- image_path：參考影像位置
- embedding：由視覺語言模型產生的高維向量表示

元資料（名稱、價格、映像路徑）儲存在關聯式資料庫中，而嵌入向量則儲存在向量資料庫中，以便進行高效的相似性搜尋。分離確保了高效的檢索，同時保持了語義向量和產品資訊之間的資料一致性。